

Algoritmo Genético para Ajuste de Função Linear

Matheus Tavares

Abril 2026

Abstract

Este documento descreve o desenvolvimento de um algoritmo genético (AG) para ajuste de uma função linear do tipo $y = ax + b$. O objetivo do projeto é encontrar os parâmetros que minimizam o erro médio quadrático entre valores observados e valores previstos. A implementação foi modularizada e organizada em múltiplos diretórios, com automação via Makefile. Os resultados indicam convergência consistente para o mínimo global.

1 Introdução

Ajustar funções a conjuntos de dados é uma tarefa recorrente em diversos domínios, como estatística, ciência de dados e engenharia. Neste projeto, implementa-se um Algoritmo Genético (AG) para estimar os parâmetros de uma função linear, buscando minimizar o erro médio quadrático (MSE).

O AG foi escolhido por sua simplicidade, capacidade de escapar de mínimos locais e aplicabilidade geral a problemas de otimização. Ainda que o problema seja convexo e possua solução analítica, o uso do AG demonstra sua aplicação didática.

2 Estrutura do Projeto

O projeto foi organizado de forma modular conforme a estrutura abaixo:

/src	Código-fonte principal (main e módulos do AG)
/include	Arquivos .h com declarações
/tools	Gerador de pontos (gerar.c)
/data	Entrada e saída (.dat)
/build	Objetos e executáveis
Makefile	Automação de compilação
README.md	Documentação geral do projeto

O arquivo `main.c` é responsável pela leitura dos dados, execução do AG e salvamento das saídas. A ferramenta `gerar.c` pode ser usada para gerar um arquivo de entrada padronizado, porém seu uso foi desabilitado para permitir edição manual de `input.dat`.

3 Descrição do Algoritmo Genético

O AG implementado segue os componentes clássicos da técnica:

3.1 População Inicial

Cada indivíduo representa um par (a, b) gerado aleatoriamente no intervalo $[-10, 10]$.

3.2 Avaliação e Fitness

O erro médio quadrático para um indivíduo é dado por:

$$E(a, b) = \frac{1}{n} \sum_{i=1}^n (y_i - (ax_i + b))^2.$$

O fitness é definido como:

$$F(a, b) = \frac{1}{E(a, b) + 0.0001}.$$

3.3 Seleção

Selecionam-se os dois indivíduos com maior fitness, usando comparação simples.

3.4 Crossover

O cruzamento gera um novo indivíduo combinando:

$$a_{\text{filho}} = a_{\text{pai1}}, \quad b_{\text{filho}} = b_{\text{pai2}}.$$

3.5 Mutação

A mutação adiciona um pequeno ruído Gaussiano ao parâmetro selecionado:

$$\Delta \sim \mathcal{N}(0, \sigma),$$

com $\sigma = 0.5$ na implementação atual.

3.6 Substituição

O indivíduo com o pior fitness é substituído pelo novo filho.

4 Entrada e Saída

4.1 Entrada

O arquivo `input.dat` contém:

```
n m G
x1 y1
x2 y2
...
xn yn
```

4.2 Saída

O arquivo `output.dat` registra, para cada geração:

- melhor indivíduo,
- valores de a e b ,
- erro médio,
- fitness correspondente.

5 Resultados e Análise de Convergência

O AG converge consistentemente para valores próximos de:

$$a \approx 2.00, \quad b \approx 4.88.$$

O erro mínimo observado é aproximadamente:

$$E_{\min} \approx 2.73.$$

Por se tratar de um problema convexo, este valor corresponde ao mínimo global real. Após atingir esta região, o algoritmo estabiliza, pois variações adicionais aumentam o erro.

6 Conclusão

A implementação do Algoritmo Genético mostrou-se funcional e eficiente para o ajuste linear proposto. O projeto demonstra o potencial de meta-heurísticas em tarefas de otimização e fornece base sólida para extensões, como ajuste polinomial, mutações adaptativas ou uso de outros operadores evolucionários.

7 Referências

- Haupt, R. L., & Haupt, S. E. (2004). *Practical Genetic Algorithms*.
- Mitchell, M. (1998). *An Introduction to Genetic Algorithms*.
- Eiben, A. E., & Smith, J. E. (2003). *Introduction to Evolutionary Computing*.